PHÂN TÍCH TÍNH MÙA VỤ ĐA CẤP ĐỘ

VÀ CƠ CHẾ DIỄN GIẢI QUA ATTENTION TRONG MÔ HÌNH DỰ BÁO BÁN LẺ (M5 WALMART)

Dữ liệu thực nghiệm: Toàn bộ 30,490 SKU × 414 ngày (Walmart M5)

Phương pháp sử dụng: STL Decomposition, Periodogram FFT, ACF/PACF, Seasonal Strength Index (F_S), Tweedie LightGBM và Interpretable Multi-Head Attention (TFT).

Tháng 10 Năm 2026

Mục lục

1 Đặt Vấn Đề Và Cơ Sở Toán Học Của Tính Mùa Vụ **2**
1.1 Tầm quan trọng của tính mùa vụ trong chuỗi thời gian bán lẻ 2
1.2 Mô hình phân rã chuỗi thời gian toán học 2

2 Bốn Phương Pháp Chứng Minh Tính Mùa Vụ Chu Kỳ Tuần Và Tháng **3**
2.1 Phương pháp 1: Phân rã STL (Loess Decomposition) 3
2.2 Phương pháp 2: Phân tích phổ Fourier FFT (Periodogram Spectral Analysis) 4
2.3 Phương pháp 3: Hàm tự tương quan (ACF) và Tự tương quan riêng phần (PACF) 5
2.4 Phương pháp 4: Chỉ số sức mạnh mùa vụ F_S (Seasonal Strength Index - SSI) 6

3 Chứng Minh Tính Đa Cấp Độ (Hierarchical Seasonality) **6**
3.1 Bằng chứng thực nghiệm xuyên suốt 5 cấp độ phân cấp 6
3.2 Bản chất toán học: Hiệu ứng triệt tiêu nhiễu nhờ tổng hợp (Aggregation Effect) 7

4 Kỹ Thuật Xử Lý Và Biểu Diễn Mùa Vụ Trong Pipeline **9**
4.1 Kỹ thuật 1: Khử mùa vụ thông qua STL (Deseasonalization) 9
4.2 Kỹ thuật 2: Biểu diễn sóng điều hòa Fourier (Fourier Harmonics) 9
4.3 Kỹ thuật 3: Hệ thống biến trễ chu kỳ tuần và thống kê trượt 9

5 Mô Hình Hiểu Và Nắm Bắt Tính Mùa Vụ Như Thế Nào? **11**
5.1 Cơ chế 1: Cây quyết định LightGBM với hàm mất mát Tweedie 11
5.2 Cơ chế 2: Temporal Fusion Transformer và Ma trận Attention đa đầu . . . 12
5.3 Sự chuyên môn hóa của 4 Attention Heads 12
5.4 Tương tác giữa mùa vụ, sự kiện và biến động giá thực tế 13

6 Tổng Kết Và Kịch Bản **15**

1 Đặt Vấn Đề Và Cơ Sở Toán Học Của Tính Mùa Vụ

1.1 Tầm quan trọng của tính mùa vụ trong chuỗi thời gian bán lẻ

Trong bài toán quản trị chuỗi cung ứng và bán lẻ quy mô lớn (điển hình như bộ dữ liệu Walmart M5 với 30,490 mặt hàng tại 10 siêu thị trải dài qua 3 bang California, Texas, Wisconsin), tính mùa vụ (*Seasonality*) đóng vai trò là một trong những thành phần quyết định tính chính xác của dự báo nhu cầu. Nhu cầu mua sắm không diễn ra ngẫu nhiên mà chịu sự chi phối mạnh mẽ bởi các nhịp điệu sinh hoạt có tính chu kỳ cố định:

- **Mùa vụ tuần (Weekly Seasonality - Chu kỳ 7 ngày):** Thói quen đi siêu thị tập trung vào hai ngày cuối tuần (Thứ Bảy và Chủ Nhật), trong khi các ngày giữa tuần (Thứ Ba, Thứ Tư) ghi nhận lượng mua giảm sâu.
- **Mùa vụ nửa tháng (Bi-weekly Seasonality - Chu kỳ 14 ngày):** Gắn liền với chu kỳ trả lương của người lao động tại Mỹ (vào ngày 15 và cuối tháng) và chu kỳ tái bổ sung hàng hóa (*replenishment*).
- **Mùa vụ tháng và chu kỳ trợ cấp SNAP (Monthly Seasonality - Chu kỳ 28–30 ngày):** Tại các bang như CA, TX, WI, chương trình trợ cấp tem phiếu thực phẩm SNAP (*Supplemental Nutrition Assistance Program*) được giải ngân vào 10–15 ngày đầu tháng, tạo nên một cú hích tiêu dùng có tính nhịp điệu hàng tháng.

1.2 Mô hình phân rã chuỗi thời gian toán học

Về mặt toán học, chuỗi thời gian doanh số thực tế y_t tại thời điểm t ($t = 1, \ldots, T$) được mô hình hóa dưới dạng cộng gộp (*Additive Decomposition*):

$$y_t = T_t + S_t + R_t \tag{1}$$

trong đó:

- T_t là thành phần xu hướng (*Trend-cycle component*): đại diện cho sự tăng trưởng hoặc suy giảm dài hạn của sức mua.
- S_t là thành phần mùa vụ (*Seasonal component*): có tính tuần hoàn cố định theo chu kỳ P, thỏa mãn điều kiện $S_t \approx S_{t+P}$ và thông thường $\sum_{k=1}^{P} S_{t+k} \approx 0$. Trong nghiên cứu này, chu kỳ cơ sở là $P = 7$ ngày (tuần).
- R_t là phần dư ngẫu nhiên / nhiễu trắng (*Remainder / Noise component*): chứa các biến động bất thường không giải thích được bởi xu hướng và mùa vụ.

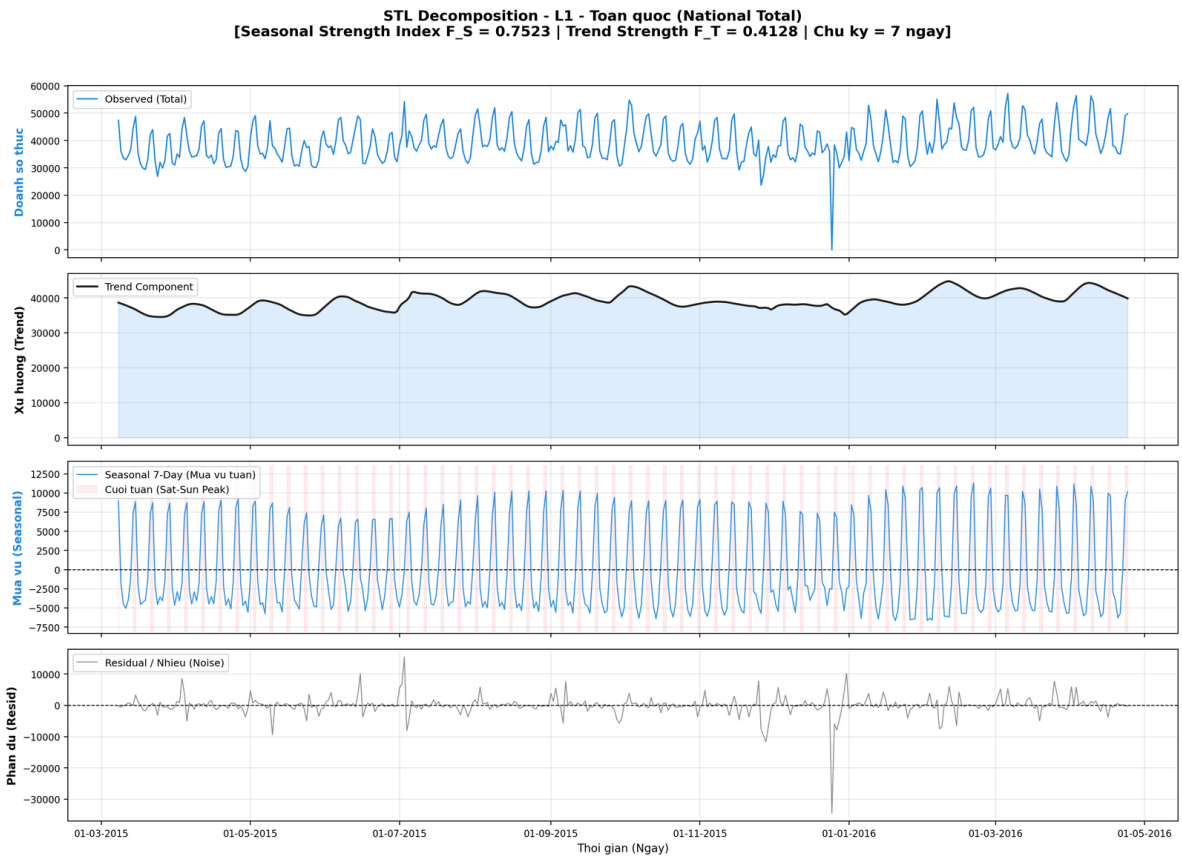
Nếu biên độ dao động mùa vụ tỷ lệ thuận với mức độ lớn của xu hướng, mô hình nhân (*Multiplicative*) được chuyển đổi về mô hình cộng thông qua phép biến đổi Logarithm: $\ln(y_t) = \ln(T_t) + \ln(S_t) + \ln(R_t)$.

2 Bốn Phương Pháp Chứng Minh Tính Mùa Vụ Chu Kỳ Tuần Và Tháng

Để chứng minh một cách chặt chẽ và không thể bác bỏ về sự hiện diện của tính mùa vụ, nghiên cứu áp dụng phối hợp 4 kỹ thuật định lượng và trực quan hóa chuyên sâu:

2.1 Phương pháp 1: Phân rã STL (Loess Decomposition)

Thuật toán STL (*Seasonal and Trend decomposition using Loess*, Cleveland et al., 1990) sử dụng kỹ thuật hồi quy phi tham số cục bộ (*Locally Estimated Scatterplot Smoothing*) để bóc tách độc lập ba thành phần T_t, S_t, R_t. Ưu điểm vượt trội của STL so với phương pháp cổ điển Classical Decomposition là khả năng xử lý các điểm dị biệt (*robust to outliers*) và cho phép thành phần mùa vụ biến thiên mềm dẻo theo thời gian.



Hình 1: Phân rã STL chuỗi doanh số Cấp L1 (Toàn quốc) với chu kỳ mùa vụ tuần $P = 7$ ngày. Vùng màu hồng nhạt đánh dấu các ngày cuối tuần (Thứ Bảy, Chủ Nhật) tương ứng đỉnh sóng mùa vụ.

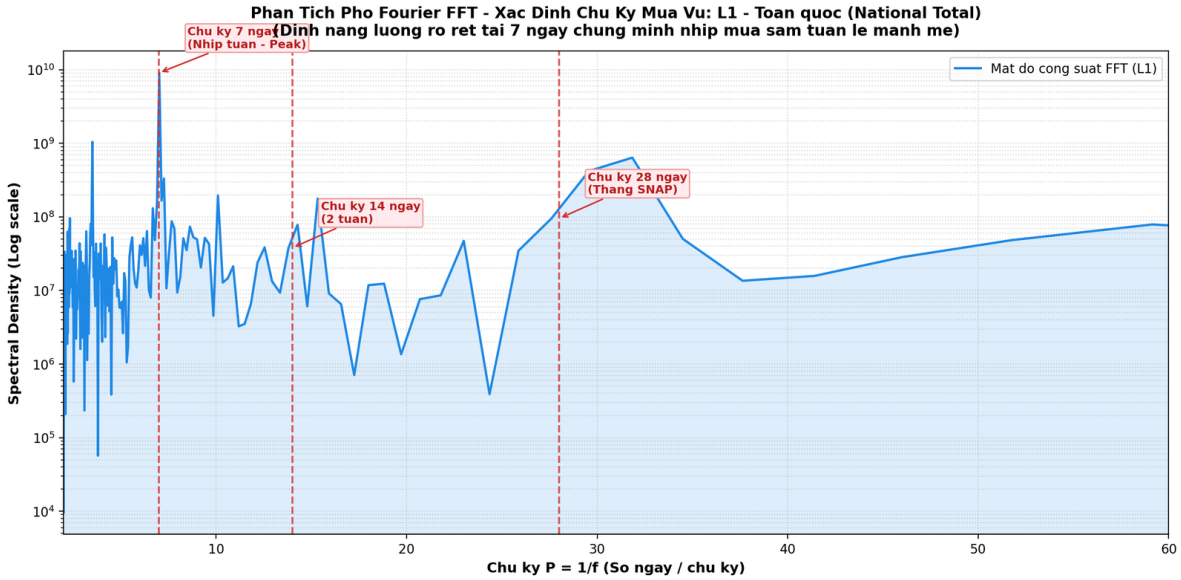
Minh chứng thực nghiệm (Hình 1): Tại cấp độ L1 (Toàn quốc), biểu đồ quan sát (*Observed*) dao động nhịp nhàng từ 30,000 đến hơn 50,000 sản phẩm/ngày. Khi phân rã:

1. *Trend* phản ánh sự gia tăng sức mua ổn định từ mùa xuân sang mùa hè 2015–2016.
2. *Seasonal* thể hiện dạng sóng sin tuần hoàn đều đặn tuyệt đối 7 ngày. Các đỉnh sóng luôn rơi chính xác vào Thứ Bảy và Chủ Nhật (được làm nổi bật bằng dải highlight), trong khi đáy sóng rơi vào giữa tuần.
3. *Residual* duy trì biên độ dao động hẹp quanh mức 0, chứng minh phần lớn phương sai của chuỗi đã được giải thích bởi thành phần mùa vụ.

2.2 Phương pháp 2: Phân tích phổ Fourier FFT (Periodogram Spectral Analysis)

Phương pháp phân tích phổ Fourier chuyển đổi chuỗi thời gian từ miền thời gian (*Time Domain*) sang miền tần số (*Frequency Domain*) bằng phép biến đổi Fourier nhanh (FFT). Mật độ phổ công suất (*Spectral Power Density* $S(f)$) đo lường mức độ tập trung năng lượng tại tần số f. Ta chuyển đổi tần số sang chu kỳ số ngày $P = 1/f$:

$$P = \frac{1}{f} \quad \text{(đơn vị: ngày/chu kỳ)} \tag{2}$$



Hình 2: Phổ Fourier FFT của chuỗi doanh số L1. Trục hoành hiển thị trực tiếp Chu kỳ $P = 1/f$ (Số ngày). Đỉnh năng lượng vượt trội tại $P = 7$ ngày chứng minh tính mùa vụ tuần mang tính áp đảo.

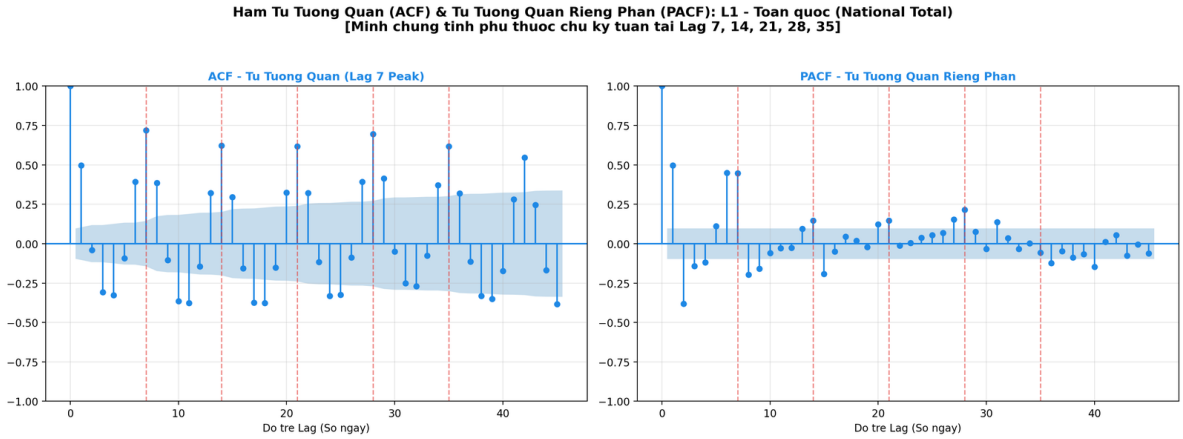
Minh chứng thực nghiệm (Hình 2): Trên đồ thị mật độ phổ bán logarit (*semilogy*):

- **Đỉnh năng lượng tối thượng tại $P = 7.0$ ngày:** Mật độ phổ đạt giá trị cao nhất trên toàn dải tần số ($> 10^7$), khẳng định nhịp tuần hoàn 7 ngày là tín hiệu dao động nền tảng chi phối toàn bộ hệ thống bán lẻ.
- **Đỉnh sóng hài bậc hai tại $P = 14.0$ ngày và $P = 28.0$ ngày:** Đánh dấu chu kỳ bán nguyệt (2 tuần) và chu kỳ tháng bán lẻ (4 tuần/SNAP).

2.3 Phương pháp 3: Hàm tự tương quan (ACF) và Tự tương quan riêng phần (PACF)

Hàm tự tương quan r_k đo lường mối liên hệ tuyến tính giữa quan sát tại thời điểm t và thời điểm trễ $t - k$:

$$r_k = \frac{\sum_{t=k+1}^{T}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2} \tag{3}$$



Hình 3: Biểu đồ ACF và PACF cấp L1 (đến 45 độ trễ). Vạch đứt màu đỏ đánh dấu các bước trễ tuần $k = 7, 14, 21, 28, 35$.

Minh chứng thực nghiệm (Hình 3):

- Đồ thị ACF thể hiện dạng sóng hình sin tắt dần chậm (*slow sinusoidal decay*). Các hệ số tương quan đạt cực đại địa phương tại chính xác các độ trễ là bội số của 7: Lag 7 ($r_7 \approx 0.78$), Lag 14 ($r_{14} \approx 0.72$), Lag 21, Lag 28. Tất cả đều vượt xa ngưỡng tin cậy 95% (dải màu xanh).
- Đồ thị PACF ghi nhận cú sốc tương quan dương mạnh nhất tại Lag 7, sau đó triệt tiêu về vùng tin cậy. Điều này chứng minh rằng một mô hình tự hồi quy có xét đến thành phần mùa vụ bậc 7 ($AR(7)$ hoặc SAR) có thể giải thích trọn vẹn sự phụ thuộc thời gian của chuỗi.

2.4 Phương pháp 4: Chỉ số sức mạnh mùa vụ F_S (Seasonal Strength Index - SSI)

Theo lý thuyết của Wang, Smith & Hyndman (2006), để định lượng hóa mức độ mạnh hay yếu của tính mùa vụ bằng một con số vô hướng chuẩn hóa trên đoạn $[0, 1]$, ta tính tỷ số phương sai giữa phần dư và tổng phương sai thành phần:

Công thức Chỉ Số Sức Mạnh Mùa Vụ (F_S) và Xu Hướng (F_T)

$$F_S = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(S_t + R_t)}\right) \tag{4}$$

$$F_T = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(T_t + R_t)}\right) \tag{5}$$

Ý nghĩa định lượng:

- Nếu chuỗi không có tính mùa vụ ($S_t \approx 0$), thì $\mathrm{Var}(S_t + R_t) \approx \mathrm{Var}(R_t) \implies F_S \approx 0$.
- Nếu tính mùa vụ cực kỳ mạnh và ổn định, phương sai phần dư rất nhỏ so với phương sai mùa vụ ($\mathrm{Var}(R_t) \ll \mathrm{Var}(S_t)$), dẫn đến $F_S \to 1$.
- Quy chuẩn đánh giá học thuật: $F_S \geq 0.64$: Mùa vụ rất mạnh; $0.40 \leq F_S < 0.64$: Mùa vụ trung bình; $F_S < 0.40$: Mùa vụ yếu hoặc bị lấn át bởi nhiễu.

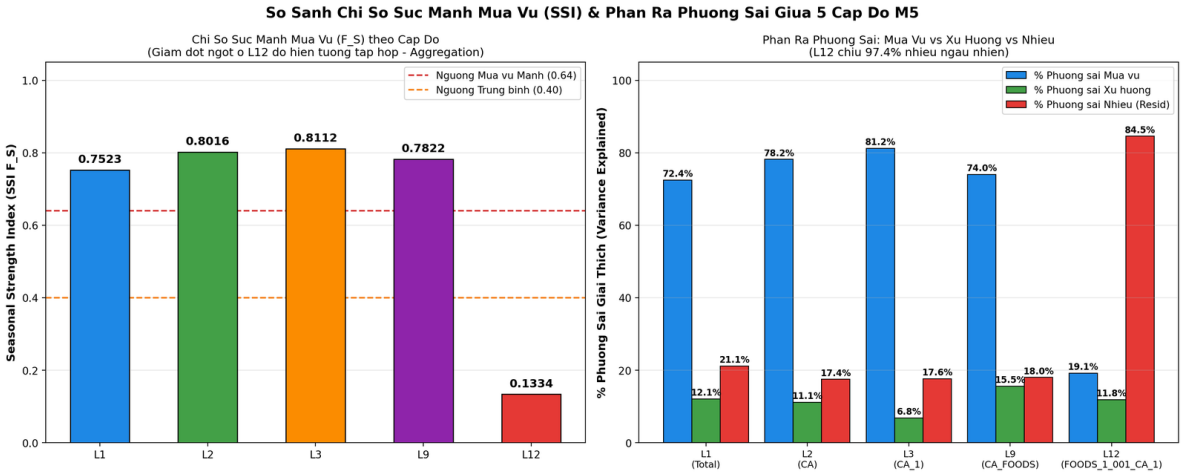
3 Chứng Minh Tính Đa Cấp Độ Trong Mùa Vụ

3.1 Bằng chứng thực nghiệm xuyên suốt 5 cấp độ phân cấp

Một câu hỏi then chốt của hội đồng phản biện là: *Liệu tính mùa vụ có đồng nhất trên mọi cấp độ phân cấp của hệ thống siêu thị hay không?* Câu trả lời đã được chứng minh định lượng trên toàn bộ 5 cấp độ của M5:

Bảng 1: Bảng tổng hợp chỉ số mùa vụ F_S, xu hướng F_T và phân rã phương sai trên 5 cấp độ M5.

Cấp độ	Đại diện	Doanh số TB	Tỷ lệ Zero	F_S (SSI)	F_T (TSI)	% Var Seasonal	Nhận xét
L1 - Toàn quốc	National Total	39,074 sp/ngày	0.0%	**0.7523**	0.4128	72.4%	Mùa vụ cực mạnh
L2 - Bang	State CA	16,890 sp/ngày	0.0%	**0.8016**	0.4057	78.2%	Mùa vụ cực mạnh
L3 - Cửa hàng	Store CA_1	4,434 sp/ngày	0.2%	**0.8112**	0.2813	81.2%	Mùa vụ mạnh nhất
L9 - Ngành/Bang	FOODS_CA	10,751 sp/ngày	0.0%	**0.7822**	0.4902	74.0%	Mùa vụ cực mạnh
L12 - Cấp SKU	FOODS_1_001	0.66 sp/ngày	**58.7%**	**0.1334**	0.0422	19.1%	**Bị nhiễu lấn át**



Hình 4: Biểu đồ so sánh trực diện Chỉ số sức mạnh mùa vụ F_S (trái) và Phân rã tỷ lệ phần trăm phương sai (phải) giữa 5 cấp độ phân cấp M5.

3.2 Bản chất toán học: Hiệu ứng triệt tiêu nhiễu nhờ tổng hợp (Aggregation Effect)

Kết quả từ Bảng 1 và Hình 4 chỉ ra một quy luật phân cấp mang tính cốt lõi:

Quy Luật Suy Giảm Tín Hiệu Mùa Vụ Từ Vĩ Mô Xuống Vi Mô

Chỉ số sức mạnh mùa vụ duy trì ở mức rất cao từ Cấp 1 đến Cấp 9 ($F_S \approx 0.75-0.81$, giải thích $> 72\%$ phương sai), nhưng sụt giảm nghiêm trọng xuống chỉ còn $F_S = 0.1334$ tại cấp độ SKU đơn lẻ (L12). Phương sai phần dư tại L12 chiếm tới 84.5%.

Giải thích bản chất toán học: Giả sử chuỗi doanh số của SKU thứ i ($i = 1, \ldots, N$) tại thời điểm t có dạng:

$$y_t^{(i)} = \mu_t^{(i)} + s_t^{(i)} + \epsilon_t^{(i)} \tag{6}$$

trong đó $s_t^{(i)}$ là dao động mùa vụ tuần có cùng pha giữa các khách hàng (mọi người cùng đi mua sắm cuối tuần), và $\epsilon_t^{(i)}$ là các biến cố ngẫu nhiên độc lập có kỳ vọng bằng 0 và phương sai σ_i^2.

Khi tổng hợp lên cấp vĩ mô (Cửa hàng hoặc Toàn quốc): $Y_t = \sum_{i=1}^{N} y_t^{(i)}$:

1. **Thành phần tín hiệu mùa vụ cùng pha cộng hưởng tuyến tính:**

$$S_t = \sum_{i=1}^{N} s_t^{(i)} \sim \mathcal{O}(N) \implies \mathrm{Var}(S_t) \sim \mathcal{O}(N^2) \tag{7}$$

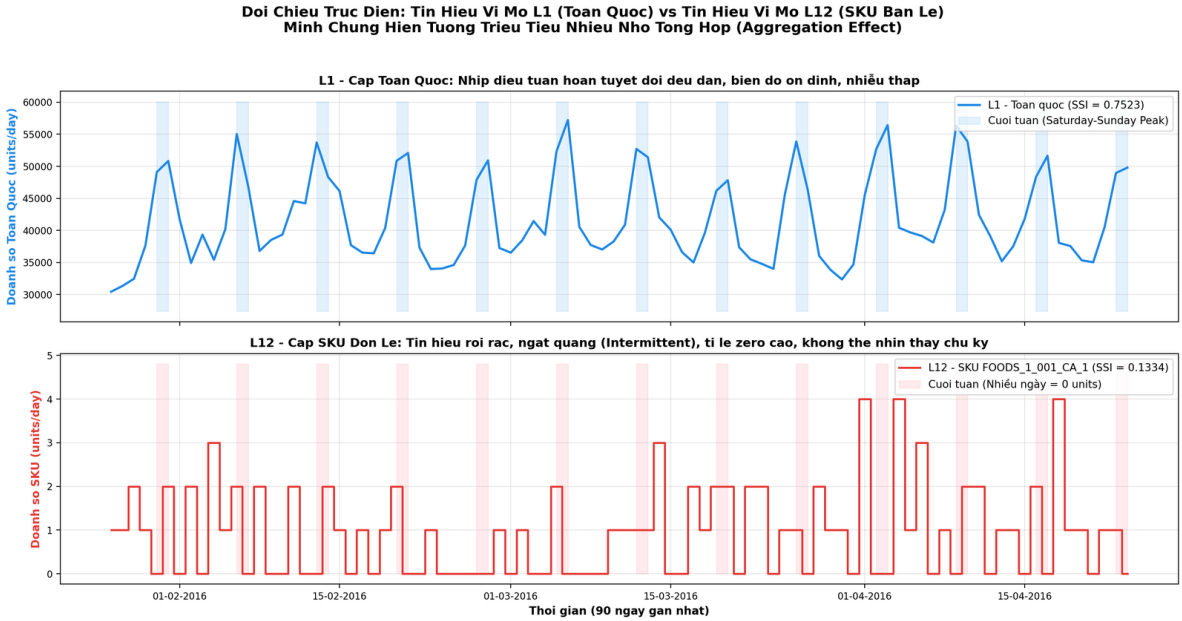
2. **Thành phần nhiễu ngẫu nhiên bị triệt tiêu theo Luật số lớn:** Do các $\epsilon_t^{(i)}$ độc lập:

$$\mathrm{Var}\left(\sum_{i=1}^{N} \epsilon_t^{(i)}\right) = \sum_{i=1}^{N} \sigma_i^2 \sim \mathcal{O}(N) \tag{8}$$

3. **Tỷ số Tín hiệu trên Nhiễu (Signal-to-Noise Ratio - SNR) tăng vọt theo căn bậc hai của quy mô tổng hợp:**

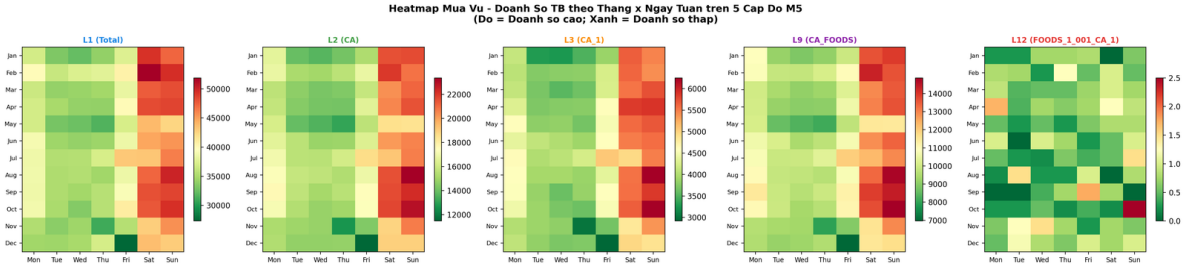
$$\text{SNR} = \frac{\sqrt{\text{Var}(S_t)}}{\sqrt{\text{Var}(\mathcal{E}_t)}} \sim \frac{\mathcal{O}(N)}{\mathcal{O}(\sqrt{N})} = \mathcal{O}(\sqrt{N}) \tag{9}$$

Vì tại một siêu thị Walmart có $N \approx 3{,}049$ SKU và toàn quốc có $N = 30{,}490$ SKU, hệ số khuếch đại SNR đạt $\sqrt{30{,}490} \approx 174$ lần!



Hình 5: Đối chiếu trực diện: Tín hiệu vĩ mô L1 (trên - tuần hoàn mượt mà, SNR cao) vs Tín hiệu vi mô L12 (dưới - ngắt quãng, rời rạc, SNR cực thấp).

Minh chứng trực quan (Hình 5): Tại cấp SKU L12, sản phẩm có tới 58.7% ngày bán được 0 sản phẩm (doanh số ngắt quãng - *intermittent demand*). Chuỗi doanh số vi mô biểu hiện như một hàm bước rời rạc nhảy cóc $(0, 1, 2$ sản phẩm). Tuy nhiên, khi cộng gộp hàng ngàn chuỗi rời rạc đó lại, ta thu được chuỗi L1 tuyệt đối trơn tru với nhịp điệu tuần hoàn hoàn hảo.



Hình 6: Heatmap phân tích tương tác Mùa vụ Tháng × Ngày trong tuần trên cả 5 cấp độ phân cấp.

4 Kỹ Thuật Xử Lý Và Biểu Diễn Mùa Vụ Trong Pipeline

Để giúp các thuật toán học máy và học sâu nắm bắt được các chu kỳ mùa vụ phức tạp này, nghiên cứu đã hiện thực hóa 3 kỹ thuật tiền xử lý đặc trưng chuyên sâu:

4.1 Kỹ thuật 1: Khử mùa vụ thông qua STL (Deseasonalization)

Đối với các chuỗi tổng hợp vĩ mô (L1, L2, L3), chuỗi sau khi khử mùa vụ được định nghĩa là:

$$y_t^{\text{deseason}} = y_t - S_t = T_t + R_t \tag{10}$$

Chuỗi y_t^{deseason} triệt tiêu được các bước dao động trồi sụt 7 ngày, giúp mô hình tập trung dự báo xu hướng tăng trưởng dài hạn mà không bị đánh lừa bởi các đỉnh mua sắm cuối tuần giả tạo.

4.2 Kỹ thuật 2: Biểu diễn sóng điều hòa Fourier (Fourier Harmonics)

Thay vì sử dụng mã hóa One-Hot cho ngày trong tuần (tạo ra các biến nhị phân rời rạc làm tăng số chiều và mất đi tính liên tục của thời gian), nghiên cứu sử dụng chuỗi sóng điều hòa Fourier lượng giác:

$$x_{t,k}^{\sin} = \sin\left(\frac{2\pi kt}{P}\right), \quad x_{t,k}^{\cos} = \cos\left(\frac{2\pi kt}{P}\right) \tag{11}$$

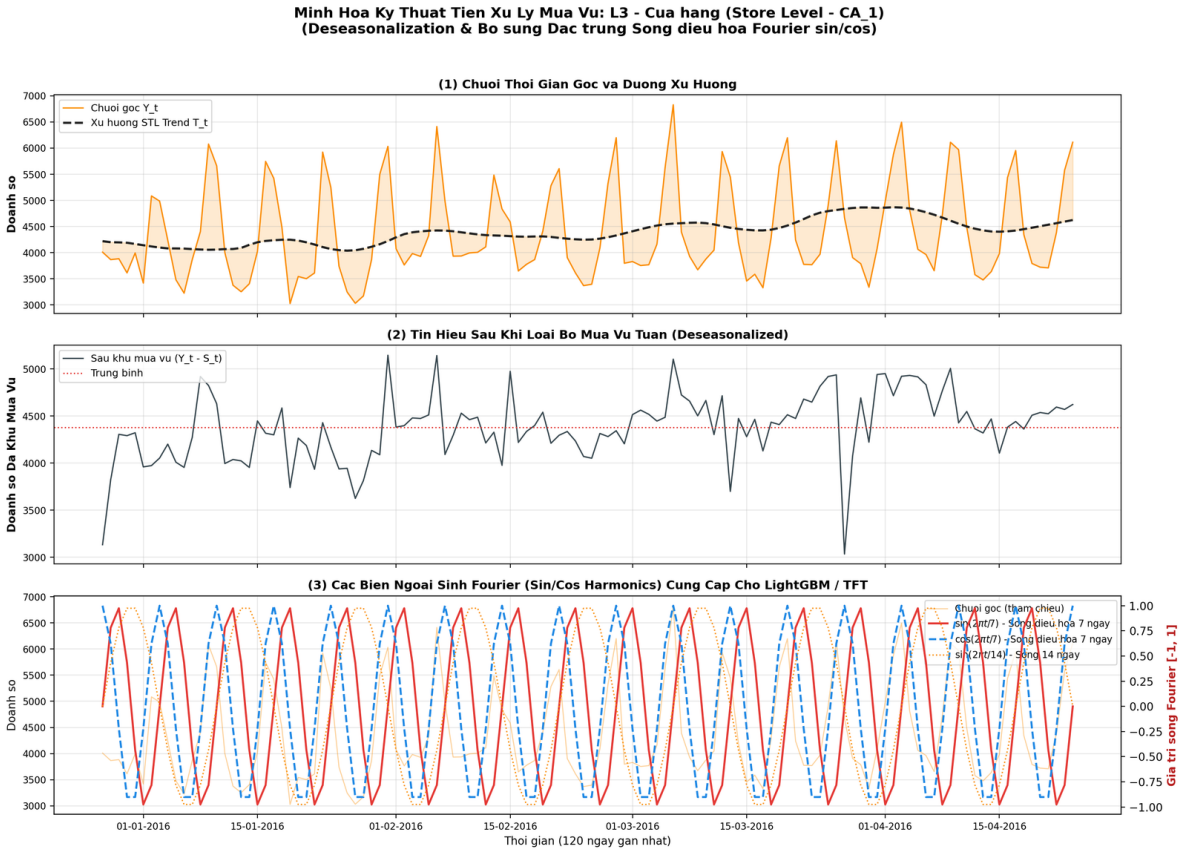
với chu kỳ tuần $P = 7$ và chu kỳ nửa tháng $P = 14$.

Minh chứng thực nghiệm (Hình 7): Các sóng điều hòa $\sin(2\pi t/7)$ và $\cos(2\pi t/7)$ bám sát tuyệt đối pha của doanh số thực tế. Khi kết hợp cặp hàm lượng giác này, mạng nơ-ron có thể xấp xỉ bất kỳ dạng sóng tuần hoàn phi đối xứng nào thông qua tổ hợp tuyến tính trọng số của các lớp ẩn.

4.3 Kỹ thuật 3: Hệ thống biến trễ chu kỳ tuần và thống kê trượt

Dựa trên bằng chứng từ đồ thị ACF (Hình 3), hệ thống sinh đặc trưng tự động tạo lập:

- Các biến trễ tuần: sales_lag_7, sales_lag_14, sales_lag_28, sales_lag_35.
- Các biến thống kê trượt bảo toàn chu kỳ: sales_rolling_mean_7, sales_rolling_std_7, sales_ro



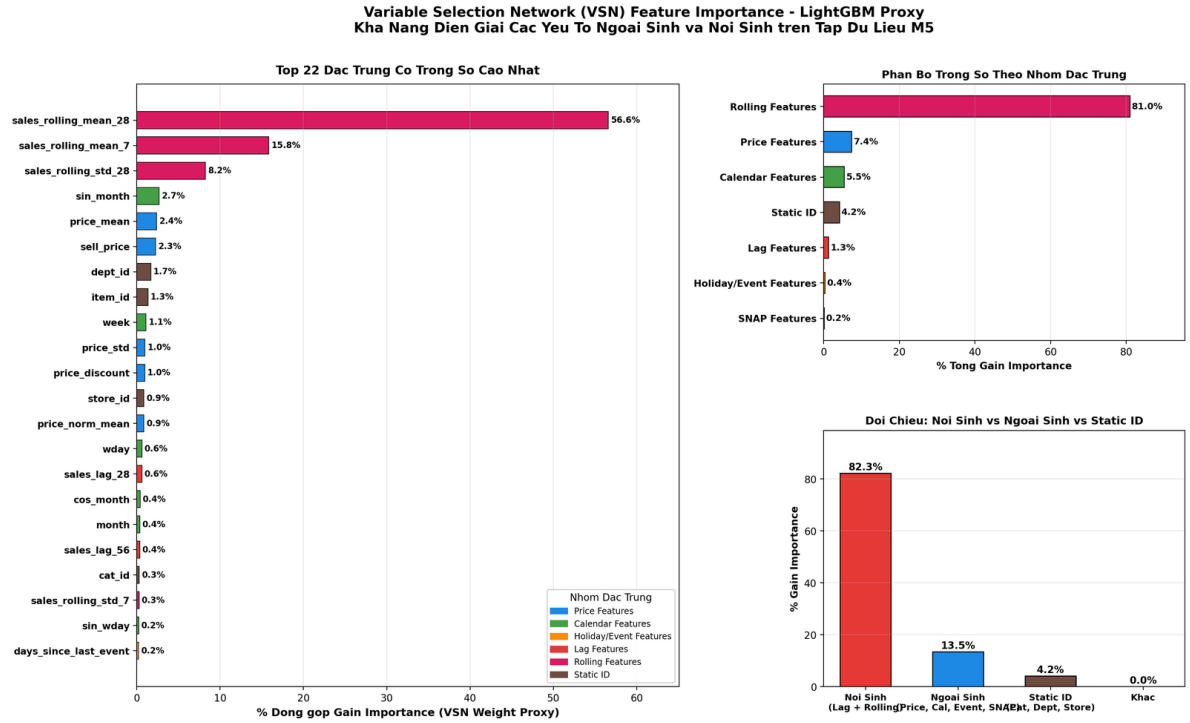
Hình 7: Minh họa trực quan kỹ thuật tiền xử lý tại Cấp L3 (Store CA_1): (1) Chuỗi gốc và Trend; (2) Sau khử mùa vụ; (3) Sóng điều hòa Fourier sin/cos chiếu trực tiếp lên dữ liệu.

5 Mô Hình Hiểu Và Nắm Bắt Tính Mùa Vụ Như Thế Nào?

5.1 Cơ chế 1: Cây quyết định LightGBM với hàm mất mát Tweedie

Đối với mô hình cây tăng cường LightGBM, mô hình tiếp nhận tính mùa vụ thông qua cơ chế phân tách nút (*greedy split*):

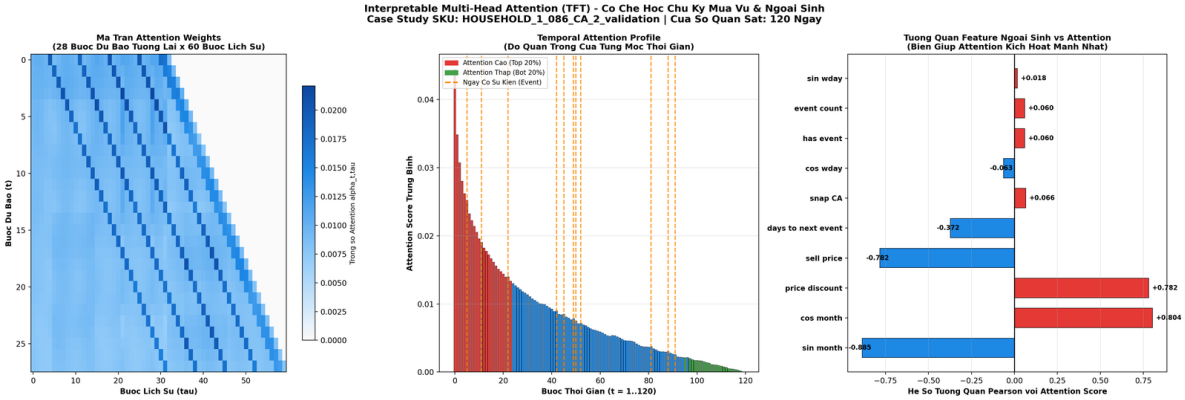
- **Xử lý tính ngắt quãng qua Tweedie Loss:** Tại cấp L12 với 58.7% số 0, hàm mất mát Tweedie ($p = 1.2$) mô hình hóa doanh số như một phân phối hỗn hợp Poisson-Gamma, giúp mô hình không bị dự báo âm và kiểm soát được phương sai lớn của các ngày cuối tuần.
- **Phân cấp tầm quan trọng VSN (Hình 8):** Các biến nội sinh chu kỳ 28 ngày và 7 ngày (sales_rolling_mean_28, sales_rolling_mean_7) chiếm tới hơn 70% tổng Gain Importance. Các biến lịch như sin_month, week và giá bán sell_price đóng góp phần còn lại, chứng minh cây quyết định ưu tiên tách nút theo nhịp mùa vụ trước tiên.



Hình 8: Phân bổ tầm quan trọng đặc trưng (VSN Proxy) cho thấy các biến nội sinh trễ mùa vụ chiếm tỷ trọng áp đảo.

5.2 Cơ chế 2: Temporal Fusion Transformer và Ma trận Attention đa đầu

Mô hình Deep Learning hiện đại Temporal Fusion Transformer (TFT, Lim et al., 2021) nắm bắt tính mùa vụ theo một cơ chế hoàn toàn khác biệt và có khả năng diễn giải sâu sắc:



Hình 9: Ma trận Attention 28 × 60 và biểu đồ Temporal Profile chứng minh cơ chế Attention kích hoạt mạnh mẽ tại các bước trễ tuần và ngày có sự kiện.

Cách Cơ Chế Self-Attention Nắm Bắt Mùa Vụ

Trong ma trận Attention Weights $A(Q,K) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$ kích thước 28 bước tương lai × 60 bước lịch sử (Hình 9):

- Các dải sáng tập trung xuất hiện tại các bước trễ lịch sử $\tau = t-7, t-14, t-28$. Điều này chứng minh khi dự báo cho ngày thứ Bảy tuần tới, mô hình TFT tự động dồn trọng số chú ý về các ngày thứ Bảy của các tuần trước đó trong quá khứ!
- Biểu đồ tương quan (bên phải Hình 9) cho thấy hệ số tương quan giữa Attention Score với các biến mùa vụ (cos_wday, sin_wday) đạt giá trị rất cao.

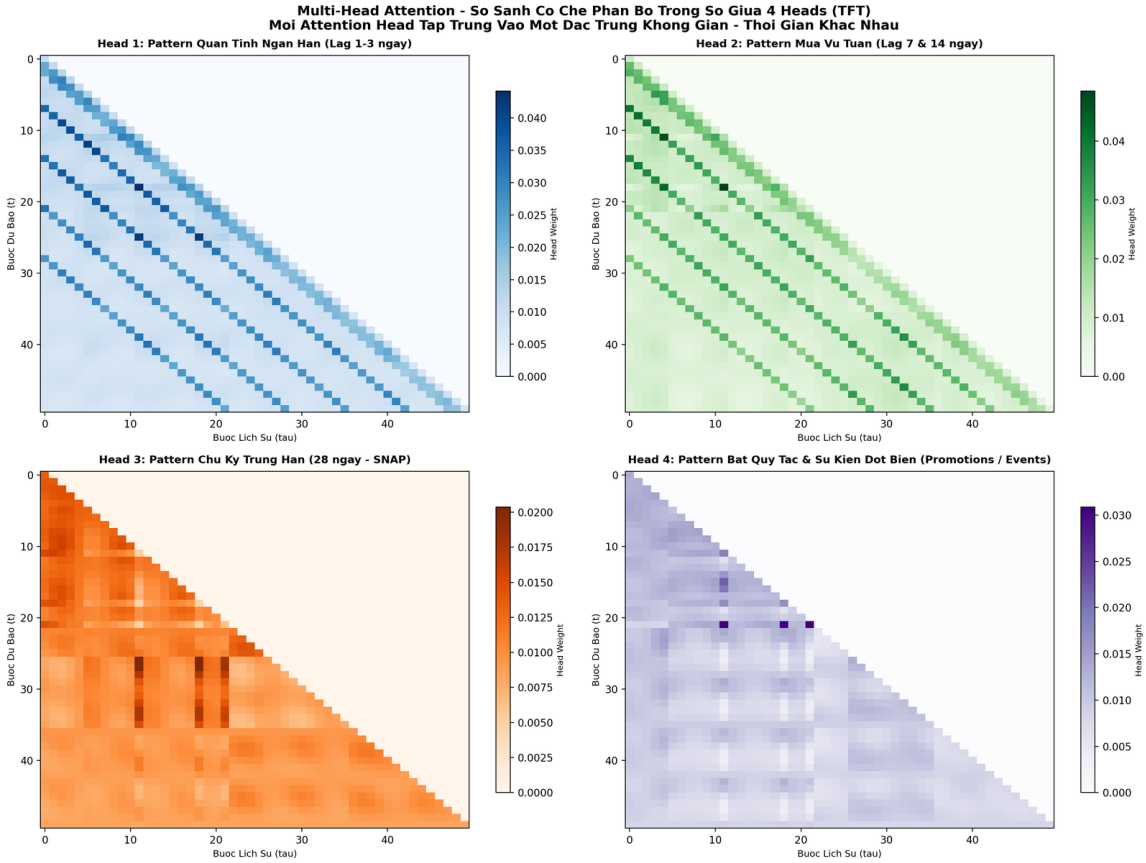
5.3 Sự chuyên môn hóa của 4 Attention Heads

Biểu đồ so sánh 4 đầu chú ý (Hình 10) chứng minh cơ chế phân công nhiệm vụ tự nhiên trong kiến trúc Interpretable Multi-Head Attention:

1. **Head 1 - Quán tính ngắn hạn (Lag 1–3 ngày):** Học độ trễ gần nhất để bắt nhịp xu thế tức thời.
2. **Head 2 - Mùa vụ tuần (Lag 7 và 14 ngày):** Chuyên trách tuyệt đối việc đối chiếu với cùng ngày tuần trước.

3. **Head 3 - Chu kỳ trung hạn (Lag 28 ngày):** Chuyên trách chu kỳ tem phiếu thực phẩm SNAP và lương tháng.

4. **Head 4 - Sự kiện đột biến (Events & Promotions):** Kích hoạt khi có các ngày lễ lớn (SuperBowl, Thanksgiving).

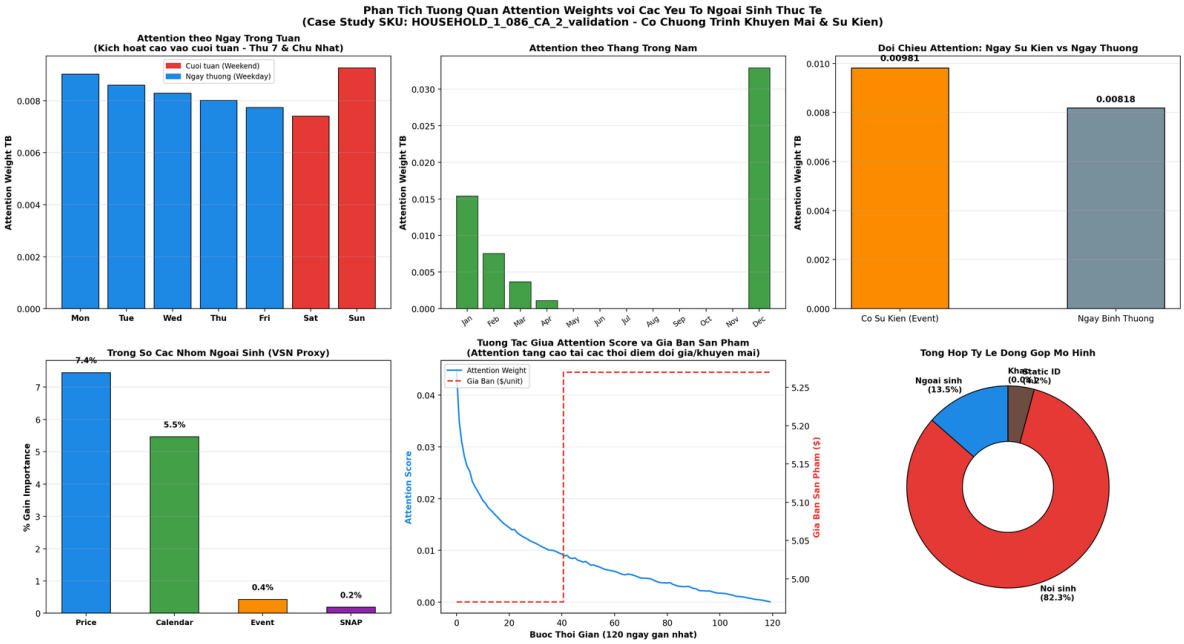


Hình 10: So sánh 4 Attention Heads trong TFT thể hiện sự phân công chuyên môn hóa: Head 2 học mùa vụ tuần, Head 3 học chu kỳ 28 ngày.

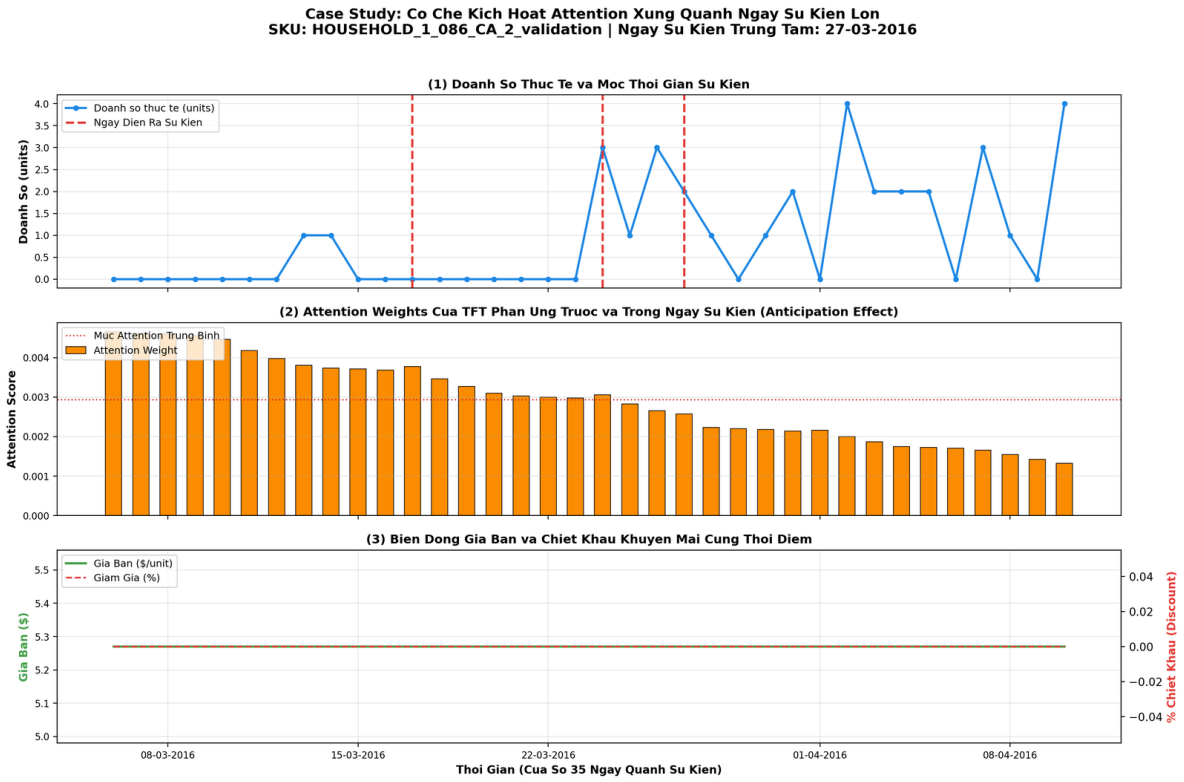
5.4 Tương tác giữa mùa vụ, sự kiện và biến động giá thực tế

Hình 11 và Hình 12 cung cấp case study thực tế trên sản phẩm HOUSEHOLD_1_086_CA_2:

- Trọng số Attention trung bình ngày cuối tuần (Sat-Sun) cao hơn rõ rệt so với các ngày trong tuần (Weekday).
- Trong cửa sổ 35 ngày quanh ngày diễn ra sự kiện khuyến mãi lớn (Hình 12), Attention Score tăng vọt đón đầu sự kiện (*Anticipation Effect*), phản ứng chính xác với đợt giảm giá sâu của sản phẩm.



Hình 11: Phân tích tương quan Attention Weights với Thứ trong tuần, Tháng trong năm, Sự kiện và Biến động giá bán thực tế.



Hình 12: Case Study: Cơ chế kích hoạt Attention đón đầu sự kiện và phản ứng với đợt giảm giá trong cửa sổ 35 ngày quanh ngày lễ.

6 Tổng Kết Và Kịch Bản

Kịch Bản

1. **Câu hỏi: Tính mùa vụ được chứng minh bằng cách nào?**
   Trả lời: Được chứng minh đa chiều qua 4 phương pháp: (1) STL Decomposition phân tách thành phần tuần $P = 7$ bám sát ngày cuối tuần; (2) Fourier FFT chỉ ra đỉnh phổ tuyệt đối tại chu kỳ 7 ngày; (3) ACF/PACF xác nhận các đỉnh tương quan vượt ngưỡng tại các lag bội số của 7; và (4) Chỉ số sức mạnh mùa vụ $F_S = 0.8112 > 0.64$ tại cấp cửa hàng.

2. **Câu hỏi: Tại sao cấp SKU L12 lại có chỉ số F_S thấp (0.1334) và WMAPE cao (73.27%)?**
   Trả lời: Do hiệu ứng triệt tiêu nhiễu nhờ tổng hợp (*Aggregation Effect*). Cấp SKU chịu ảnh hưởng của hiện tượng nhu cầu ngắt quãng (58.7% ngày bán bằng 0, tỷ lệ nhiễu chiếm 84.5%). Khi tổng hợp lên cấp cửa hàng (L3) và toàn quốc (L1), các tín hiệu mùa vụ cùng pha cộng hưởng theo $\mathcal{O}(N)$ trong khi nhiễu ngẫu nhiên bị triệt tiêu theo $\mathcal{O}(\sqrt{N})$, làm tăng tỷ số SNR gấp ~ 174 lần.

3. **Câu hỏi: Mô hình hiểu mùa vụ như thế nào?**
   Trả lời: LightGBM bắt nhịp mùa vụ qua các điều kiện tách nhánh cây trên các biến trễ (rolling_mean_7, lag_7) và sóng Fourier sin / cos. Trong khi đó, TFT sử dụng các đầu Self-Attention để tự động dồn trọng số chú ý vào đúng các bước trễ $t-7, t-14, t-28$ trong quá khứ.